

8-series-de-tiempo

November 16, 2023

1 8. Series de tiempo no estacionarias


Francisco Mestizo Hernández A01731549


1.1 Ventas de televisores

1.1.1 *Aditivo*

Primero, hacemos un análisis de los datos, graficandolos. Podemos ver que hay tres ciclos en la gráfica. Y también podemos ver que tiene una tendencia lineal ascendente.

```
[2]: ventas = c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
      ↪8.4)
x= ts(ventas, frequency = 4, start=c(2016,1))
plot.ts(x, col = "red")
T = decompose(x)
plot(T, col = "blue")
```





Y aqui podemos la estacionalidad de los datos

```
[3]: T$seasonal
```

		Qtr1	Qtr2	Qtr3	Qtr4
A Time Series: 4 × 4	1	-0.4395833	-1.0687500	0.5895833	0.9187500
	2	-0.4395833	-1.0687500	0.5895833	0.9187500
	3	-0.4395833	-1.0687500	0.5895833	0.9187500
	4	-0.4395833	-1.0687500	0.5895833	0.9187500

Podemos generar un modelo lineal para ver como se comporta con las ventas desestacionalizadas (después del aplanamiento). El modelo se puede ver gráficoado abajo.


```
[4]: ventas_desestacionalizadas = (T$x)/(T$seasonal)
x3 = 1:16
y3 = ventas_desestacionalizadas
N3 = lm(y3~x3)
N3
plot(x3, y3, type = "l")
abline(N3, col = "red")
text(6, 7, " ventas = -3.5443 + 0.4847 trimestre")
```

Call:

```
lm(formula = y3 ~ x3)
```

Coefficients:

(Intercept)	x3
-3.5443	0.4847



Aún así, cuando obtenemos los detalles del modelo vemos que las variables no son significativas. Además, que la R cuadrada es muy pequeña

```
[5]: summary(N3)
```

Call:

```
lm(formula = y3 ~ x3)
```

Residuals:

Min	1Q	Median	3Q	Max
-17.088	-8.085	1.836	8.971	12.267

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-3.5443	5.5166	-0.642	0.531
x3	0.4847	0.5705	0.850	0.410

Residual standard error: 10.52 on 14 degrees of freedom

Multiple R-squared: 0.04902, Adjusted R-squared: -0.0189

F-statistic: 0.7217 on 1 and 14 DF, p-value: 0.4099

Las predicciones que obtenemos con este modelo lineal serían las siguientes.

```
[6]: f = function(x) {-3.5443 + 0.4847*x}
# Los índices estacionales son:
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4];
f(17)*a1*1000
f(18)*a2*1000
f(19)*a3*1000
f(20)*a4*100
```

-2064.1075

-5536.445625


3339.98958333334


565.0036875

1.1.2 Multiplicativo

Podemos intentar hacer el modelo multiplicativo en lugar de aditivo. Veamos los resultados

```
[7]: ventas = c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
x= ts(ventas, frequency = 4, start=c(2016,1))
plot.ts(x, col = "red")
T = decompose(x, type="m")
plot(T, col = "blue")
```





En la gráfica podemos ver que la línea se ajusta mucho mejor a los datos, por lo tanto es muy probable que este modelo sea mejor.


```
[8]: ventas_desestacionalizadas = (T$x)/(T$seasonal)
x3 = 1:16
y3 = ventas_desestacionalizadas
N3 = lm(y3~x3)
N3
plot(x3, y3, type = "l")
abline(N3, col = "red")
text(6, 7, " ventas = 5.1080 + 0.1474 trimestre")
```

Call:


```
lm(formula = y3 ~ x3)
```

Coefficients:

(Intercept)	x3
5.1080	0.1474



Si vemos los detalles del modelo comprobamos que las variables son significativas y que la R cuadrada aumento muchísimo, hasta tener un valor de 0.92

```
[9]: summary(N3)
```

Call:

```
lm(formula = y3 ~ x3)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.5007	-0.1001	0.0037	0.1207	0.3872

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.10804	0.11171	45.73	< 2e-16 ***
x3	0.14738	0.01155	12.76	4.25e-09 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.213 on 14 degrees of freedom

Multiple R-squared: 0.9208, Adjusted R-squared: 0.9151

F-statistic: 162.7 on 1 and 14 DF, p-value: 4.248e-09

Y las predicciones que se obtienen son las siguientes. Podemos ver que tienen más sentido que las obtenidas en el primer modelo. Las predicciones que se muestran son para el año siguiente (los siguientes cuatro trimestres)

```
[10]: f = function(x) {5.1080 + 0.1474*x}
# Los índices estacionales son:
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4]
pred1 = f(17)*a1*1000
pred2 = f(18)*a2*1000
pred3 = f(19)*a3*1000
pred4 = f(20)*a4*1000
pred1
pred2
pred3
pred4
```

7085.8720956619

6491.28393942345

8632.58539314895

9195.26262943307

1.1.3 Validez del modelo

Podemos ver si el modelo que obtuvimos el valido se le harán pruebas de validez.

```
[11]: A = N3
      shapiro.test(A$residuals)


      #Gráficas auxiliares:
      qqnorm(A$residuals)
      qqline(A$residuals)


      plot(A$residuals)
      abline(h = 0, col = "red")
```

Shapiro-Wilk normality test

data: A\$residuals

W = 0.96379, p-value = 0.7307





El resultado que obtenemos del test de shapiro indica normalidad. Se puede ver que en el gráfico de la Q-Q Plot los datos estan sobre las lineas pero las colas sí quedan un poco separadas. Además, los residuos nos muestran claramente un comportamiento cuadrático, ya que al inicio y al final están por debajo de la linea, pero en medio estan por encima. Esto puede indicar que es mejor que utilicemos otro modelo, como el cuadrático. Esto lo probaremos más adelante.

1.1.4 CME2 y EPAM

También se pueden comprobar los errores del modelo, tanto el cuadratico como el porcentual.

```
[12]: predicciones = NA
      e = NA
      EPAM_todos = NA
      for(i in 1:16){
```

```

predicciones[i] = f(i)*T$seasonal[i]
e[i] = ventas[i]-predicciones[i]
EPAM_todos[i] = abs(e[i]) / ventas[i]
}

```

```

[13]: CME2=mean(ventas_deestacionalizadas^2,na.rm="TRUE")
EPAM = mean(EPAM_todos)
CME2
EPAM

```

40.960922120052

0.0243939555957905

Los resultados que obtenemos es que el modelo explica el 98% de los casos ya que solo tiene un error del 2%. Esto nos puede indicar que es un modelo bastante bueno.

1.1.5 Predicciones

Con las predicciones que se realizaron para el segundo modelo (multiplicativo) podemos ver que tan cerca quedan de los valores reales. En general, las predicciones son bastante cercanas a la realidad.


Además, podemos volver a ver el error, donde confirmamos que tiene un comportamiento cuadrático, como habíamos visto arriba.


```

[14]: plot(1:16, ventas, col = "red", type = "b", pch = 16, lty = 1, ylim = c(
  ↪ min(c(ventas, predicciones)), max(c(ventas, predicciones))), xlab = "
  ↪ X-axis Label", ylab = "Y-axis Label")
lines(1:16, predicciones, col = "blue", type = "b", pch = 16, lty = 1)
legend("topright", legend = c("Ventas", "Predicciones"), col = c("red", "
  ↪ blue"), lty = 1)

plot(e, col = "magenta")
legend("topright", legend = c("Error"), col=c("magenta"), lty=1)

```





1.1.6 Un mejor modelo: Cuadrático

Como vimos arriba, aunque el modelo era bueno, parecía que se podría hacer mucho mejor, podemos probar hacer el mismo procedimiento pero ahora con un modelo cuadrático.

```
[15]: x= ts(ventas, frequency = 4, start=c(2016,1))
      T = decompose(x, type="m")
```

```
[16]: ventas_desestacionalizadas = (T$x)/(T$seasonal)
      x3 = 1:16
      y3 = ventas_desestacionalizadas
      N3 = lm(y3 ~ x3 + I(x3^2))
      summary(N3)
```


Call:

```
lm(formula = y3 ~ x3 + I(x3^2))
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.36986	-0.07058	-0.00100	0.11345	0.33110

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	4.790283	0.152429	31.426	1.20e-13	***
x3	0.253302	0.041269	6.138	3.56e-05	***
I(x3^2)	-0.006231	0.002360	-2.640	0.0204	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1784 on 13 degrees of freedom

Multiple R-squared: 0.9484, Adjusted R-squared: 0.9405

F-statistic: 119.6 on 2 and 13 DF, p-value: 4.268e-09

Podemos ver que todas las variables son significativas y obtuvimos una R cuadrada todavia mejor. Subió de 0.915 a 0.94

```
[17]: A = N3
shapiro.test(A$residuals)


#Gráficas auxiliares:
qqnorm(A$residuals)
qqline(A$residuals)


plot(A$residuals)
abline(h = 0, col = "red")
```

Shapiro-Wilk normality test

data: A\$residuals

W = 0.96004, p-value = 0.6625





Además las colas ya no están tan alejadas y los residuos ya no parecen presentar un comportamiento. Aún así, quizás este modelo todavía podría ser mejorado. Y el test de shapiro nos indica normalidad

```
[18]: f = function(x) {4.790283 + 0.253302*x -0.006231*x*x}
# Los índices estacionales son:
a1 = T$seasonal[1]
a2 = T$seasonal[2]
a3 = T$seasonal[3]
a4 = T$seasonal[4]
pred1 = f(17)*a1*1000
pred2 = f(18)*a2*1000
pred3 = f(19)*a3*1000
pred4 = f(20)*a4*1000
```

```
pred1  
pred2  
pred3  
pred4
```

6789.78951925353

6131.37029704438

8026.81118334748

8405.31355113241

Finalmente, con este nuevo modelo podemos hacer una prediccion para el siguiente año.

1.2 Un problemilla más: Libros de texto

- 1) Encuentre los promedios móviles de cuatro trimestres y los promedios móviles centrados

```
[19]: anio1 <- c(1690, 940, 2625, 2500)  
anio2 <- c(1800, 900, 2900, 2360)  
anio3 <- c(1850, 1100, 2930, 2615)  
  
# Suma móvil de cuatro trimestres  
promediosMoviles <- (anio1 + anio2 + anio3) / 3  
# Promedio móvil centrado de cuatro trimestres  
promediosMovilesCentrados <- filter(c(anio1, anio2, anio3), rep(1, 3))/3  
  
cat("Promedio Móvil de Cuatro Trimestres:", promediosMoviles, '\n\n')  
  
cat("Promedio Móvil Centrado de Cuatro Trimestres:", promediosMovilesCentrados)
```

Promedio Móvil de Cuatro Trimestres: 1780 980 2818.333 2491.667

Promedio Móvil Centrado de Cuatro Trimestres: NA 1751.667 2021.667 2308.333
1733.333 1866.667 2053.333 2370 1770 1960 2215 NA

- 2) Calcule los índices estacionales de los cuatro trimestres

```
[20]: # Promedios móviles centrados de cuatro trimestres  
promedio_movil_centrado_cuatro_trimestres <- filter(ventas, rep(1, 3))/3  
  
# Índices estacionales  
indices_estacionales <- ventas / promedio_movil_centrado_cuatro_trimestres  
  
# Imprimir resultados  
print("Índices Estacionales:")  
print(indices_estacionales)
```

[1] "Índices Estacionales:"
Time Series:

```

Start = 1
End = 16
Frequency = 1
[1] NA 0.8255034 1.0843373 1.0655738 0.9942857 0.8764045 1.0515464
[8] 1.0990099 0.9473684 0.8795812 1.0765550 1.0833333 0.9450000 0.8762376
[15] 1.0762332 NA

```

- 3) ¿Cuándo obtiene la editorial el mayor índice estacional? ¿Parece razonable este resultado?
 ¿Por qué?

```

[21]: # Encontrar el trimestre con el mayor índice estacional
trimestre_max_estacional <- which.max(indices_estacionales)

# Imprimir resultados
print("Trimestre con el Mayor Índice Estacional:")
print(trimestre_max_estacional)

# Obtener el año y trimestre correspondiente
anio_correspondiente <- ceiling(trimestre_max_estacional / 4)
trimestre_correspondiente <- trimestre_max_estacional %% 4
if (trimestre_correspondiente == 0) trimestre_correspondiente <- 4

print("Año y Trimestre Correspondiente:")
print(paste("Año", anio_correspondiente, ", Trimestre",
  ↪trimestre_correspondiente))

```

```

[1] "Trimestre con el Mayor Índice Estacional:"
[1] 8
[1] "Año y Trimestre Correspondiente:"
[1] "Año 2 , Trimestre 4"

```

El resultado que obtenemos es que el trimestre con mayor índice estacional es el tercero del año. Esto tiene sentido, ya que es el trimestre en el que inician los ciclos escolares de la mayoría de las escuelas. Por lo tanto, hay más compras de libros de texto.